

РТУ МИРЭА

Кафедра высшая математика 3

Теория вероятностей и математическая
статистика



Лекция 7

Основные понятия математической статистики

Для студентов ИИТ

Берков Николай Андреевич

10 мая 2024г

1. Предмет математической статистики.

Математическая статистика - это наука, которая методами теории вероятностей на основании результатов наблюдений изучает закономерности в массовых случайных явлениях. Математическая статистика указывает способы сбора и группировки статистических данных (результатов наблюдений), разрабатывает методы их обработки для оценки характеристик распределения, для установления зависимости случайной величины от других, для проверки статистических гипотез о виде распределения или значениях его параметров.

Значительная часть математической статистики связана с необходимостью описать большую совокупность объектов.

Определение 1. Совокупность объектов, свойства которых нужно изучить называют **генеральной**.

Если генеральная совокупность слишком многочисленна, или ее объекты труднодоступны, или имеются другие причины, не позволяющие изучить все объекты, прибегают к изучению какой-то части объектов.

Определение 2. Совокупность объектов, отобранных из генеральной совокупности для исследования, называется **выборкой**.

Необходимо, чтобы выборка наилучшим образом представляла генеральную совокупность, т.е. была **репрезентативной** (представительной).

Если генеральная совокупность мала или совсем неизвестна, не удастся предложить ничего лучшего, чем чисто случайный выбор.



ПРИМЕР 7.1. Пусть необходимо оценить качество изделий, выпускаемых определённым цехом машиностроительного предприятия. Для этого выбирают партию изделий и подвергают их контролю с целью дефектирования. Доля бракованных изделий для выбранной партии распространяется затем на всю продукцию цеха.

Здесь генеральная совокупность — все изделия, выпускаемые цехом, выборка — отобранные для проверки изделия.

ПРИМЕР 7.2. Пусть необходимо оценить будущий урожай пшеницы. Для этого выбирают небольшой участок поля, например один квадратный метр, и подсчитывают число зерен во всех колосках и их массу. Приблизённо весь урожай равен площади поля в метрах, умноженной на массу зерен, собранную с данного участка. Здесь генеральная совокупность — весь ожидаемый урожай, а выборка — урожай, собранный с одного квадратного метра. Если выбрать «плохой» участок (например, близко к краю поля), то оценка урожая будет заниженной. Если же участок имеет преимущества перед другими (например, лучше освещается солнцем), то оценка урожая будет завышенной.



Будем проводить испытания и в каждом из них фиксировать значения, которые приняла случайная величина ξ . В результате n испытаний получим выборку n значений, образующих простую статистическую совокупность наблюдений.

Определение 3. Количество наблюдений n называется **объемом выборки**.

При большом числе наблюдений (сотни, тысячи) простая статистическая совокупность перестает быть удобной формой записи статистического материала - она становится слишком большой. Для более экономичной записи наблюдаемые значения группируют.

Пусть в выборке значение x_1 наблюдалось n_1 раз, x_2 - n_2 раз, ..., x_k - n_k раз и

$$\sum_{i=1}^k n_i = n - \text{объем выборки.}$$

Определение 4. Наблюдаемые значения x_i называют **вариантами**, а их последовательность, записанная в возрастающем порядке - **вариационным рядом**. Количество наблюдений $n_1, n_2, \dots, n_k$ называют **частотами**.

Определение 5. **Статистическим распределением** (статистическим рядом) выборки называют перечень вариантов и соответствующих им частот.

варианты x_i	x_1	...	x_k
частоты n_i	n_1	...	n_k

2. Эмпирическая функция распределения и гистограмма.

С каждым испытанием, в котором наблюдается некоторая случайная величина ξ , можно связать случайное событие $\xi = x_i$, но иногда удобнее рассматривать событие $\xi < x_i$.

Определение 6. Эмпирической (статистической) функцией распределения случайной величины ξ называется функция $F^*(x)$, которая при каждом x равна относительной частоте события $\xi < x$, т.е. отношению n_x - числа наблюдений меньших x к объему выборки n :

$$F^*(x) = P^*(\xi < x) = \frac{n_x}{n}.$$

Из определения $F^*(x)$ вытекают ее свойства:

- 1) $0 \leq F^*(x) \leq 1$;
- 2) $F^*(x)$ - ступенчатая неубывающая функция;
- 3) если x_1 - наименьшая, а x_k - наибольшая варианты, то $F^*(x) = 0$ при $x \leq x_1$ и $F^*(x) = 1$ при $x > x_k$.


Пример 1. Построить эмпирическую функцию распределения для данной выборки:

x_i	1	4	6	7	8	10
n_i	5	10	15	5	10	5

x_i	1	4	6	7	8	10
n_i	5	10	15	5	10	5

Решение: Объем выборки $n = 5 + 10 + 15 + 5 + 10 + 5 = 50$.

$$F^*(x) = \begin{cases} 0 & \text{при } x \leq 1 \\ \frac{5}{50} = 0.1 & \text{при } 1 < x \leq 4 \\ \frac{5+10}{50} = 0.3 & \text{при } 4 < x \leq 6 \\ \frac{5+10+15}{50} = 0.6 & \text{при } 6 < x \leq 7 \\ \frac{5+10+15+5}{50} = 0.7 & \text{при } 7 < x \leq 8 \\ \frac{5+10+15+5+10}{50} = 0.9 & \text{при } 8 < x \leq 10 \\ \frac{5+10+15+5+10+5}{50} = 1 & \text{при } x > 10 \end{cases}$$



Гистограмма (геометрическое изображение статистической совокупности) представляет выборку более наглядно.

Для построения гистограммы разделим весь диапазон наблюдений на s интервалов вида $(a_{j-1}; a_j]$ и определим количество наблюдений m_j , попавших в j -й интервал.

Относительная частота наблюдений, попавших в j -й интервал равна $P_j^* = \frac{m_j}{n}$

($m_1 + m_2 + \dots + m_s = n$), сумма всех относительных частот, очевидно, равна единице.


Для построения гистограммы по оси ординат откладываются значения $\frac{P_j^*}{\Delta a_j} = \frac{m_j}{n(a_j - a_{j-1})}$.

Полученная фигура, состоящая из прямоугольников, называется **гистограммой относительных частот**. Площадь каждого прямоугольника равна относительной частоте наблюдений, попавших в данный интервал.

Для примера 1 получим следующую гистограмму:


x_i	1	4	6	7	8	10
n_i	5	10	15	5	10	5

№ п/п	a_{j-1}	a_j	m_j	$P_j^* = \frac{m_j}{n}$	$\frac{P_j^*}{\Delta a_j}$
1	0	3	5	0.1	1/30
2	3	6	25	0.5	5/30
3	6	9	15	0.3	3/30
4	9	12	5	0.1	1/30



Другим наглядным способом представления распределения является **полигон относительных частот**. Для его построения по оси абсцисс откладываются варианты, а по оси ординат - относительные частоты, и полученные точки соединяются ломаной линией.

Для примера 1 получим следующий полигон относительных частот:



x_i	1	4	6	7	8	10
n_i	5	10	15	5	10	5

Для выборки из генеральной совокупности значений непрерывной случайной величины гистограмма является статистическим аналогом плотности распределения, а для дискретной случайной величины полигон относительных частот является статистическим аналогом многоугольника вероятностей.

При увеличении объема выборки эти статистические характеристики в определенном смысле приближаются к своим теоретическим аналогам.

Замечание. Наряду с гистограммой и полигоном относительных частот иногда рассматривают соответственно гистограмму и полигон частот, отличающиеся масштабом по оси ординат - все значения по оси ординат умножаются на n - объем выборки. Понятно, что форму получаемых фигур это не изменяет.



3. Числовые характеристики статистического распределения.

Статистическая функция распределения и гистограмма являются полными характеристиками результатов наблюдения случайной величины в данной серии испытаний. Однако иногда целесообразно ограничиться более простой, хотя и неполной характеристикой распределения.

Простейшей характеристикой распределения является **выборочное среднее**, которое для простой статистической совокупности вычисляется по формуле:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

Если данные сгруппированы, то:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k n_i \cdot x_i \quad (2)$$

Для характеристики разброса значений случайной величины относительно ее среднего значения используется **выборочная дисперсия**

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (3)$$

для простой совокупности и

$$S^2 = \frac{1}{n} \sum_{i=1}^k n_i (x_i - \bar{x})^2 \quad (4)$$

для сгруппированного распределения.



Очевидно, выборочная дисперсия имеет ту же размерность, что и квадрат случайной величины. Практически удобно пользоваться величиной, имеющей ту же размерность, что и данная случайная величина. Для этого достаточно из дисперсии извлечь квадратный корень.

Эта величина

$$S = \sqrt{S^2} \quad (5)$$

называется **выборочным средним квадратическим отклонением СКО**).

На практике вместо формулы (3) бывает удобнее применять другую формулу:

$$S^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - (\bar{x})^2 = \overline{x^2} - (\bar{x})^2 \quad (6)$$

для простой совокупности и

$$S^2 = \frac{1}{n} \sum_{i=1}^n n_i x_i^2 - (\bar{x})^2 = \overline{x^2} - (\bar{x})^2 \quad (7)$$

для сгруппированного распределения.

Выборочное среднее, выборочная дисперсия и среднее квадратическое отклонение являются примерами точечных оценок параметров распределения.



Модой статистического распределения (обозначается M_O) называется значение которое наиболее часто встречается в исследуемой выборке.

Например, для ряда 2, 2, 4, 5, 5, 5, 5, 6, 6, 7, $M_O = 5$. Встречаются распределения, называемые мультимодальными или полимодальными, в которых имеются несколько значений M_O . Например: 1, 2, 2, 3, 4, 5, 5, 6, 6, 7, модами будут три значения $M_O = \{2, 5, 6\}$.

Медианой (M_e) называется значение, которое разбивает выборку на две равные части. Половина наблюдений лежит ниже медианы, и половина наблюдений лежит выше медианы.

Медиана вычисляется следующим образом. Изучаемая выборка упорядочивается в порядке возрастания. Получаемая последовательность в виде неубывающей последовательности (вариационного ряда) x_i , где $i = 1, \dots, n$, где n – объем выборки. Если объем выборки нечетное число, то $M_e = x_{(n+1)/2}$, иначе $M_e = (x_{n/2} + x_{n/2+1})/2$.

Например, для вариационного ряда $\{1, 3, 5, 7, 9, 9, 12\}$ медиана равна третьему элементу $M_e = 7$, а для вариационного ряда $\{1, 3, 5, 7, 9, 12\}$ медиана равна среднему значению второго и третьего элементов $M_e = (5 + 7)/2 = 6$.

Для выборки представленной в виде сгруппированного распределения значений моды и медианы аппроксимируются по следующим формулам



Для выборки представленной в виде сгруппированного распределения значений моды и медианы аппроксимируются по следующим формулам

$$M_O = X_O + h \frac{f_{m0} - f_{m0-1}}{2f_{m0} - f_{m0-1} - f_{m0+1}}, \quad (12.1)$$

где X_O – нижнее значение модального интервала; $f_{m0}, f_{m0-1}, f_{m0+1}$ – значение частот в модальном интервале, предыдущем и в следующем интервалах, соответственно; h – размах интервала.

$$M_e = X_O + h \frac{0,5 \sum_{k=1}^s f_k - \sum_{k=1}^{me-1} f_k}{f_{me}}, \quad (12.2)$$

где X_O – нижняя граница интервала, в котором находится медиана; me – номер медианного интервала; f_{me} – значение частоты в медианном интервале.



ПРИМЕР 12.7. Из генеральной совокупности объёма $N = 10000$ извлечена выборка объёма $n = 50$, результаты которой сгруппированы и помещены в таблицу.

i	1	2	3	4	5	6
$(x_i; x_{i+1}]$	$(10; 14]$	$(14; 18]$	$(18; 22]$	$(22; 26]$	$(26; 30]$	$(30; 34]$
n_i	4	11	15	12	6	2

1) Построить гистограмму относительных частот по сгруппированным данным, где n_i – частота попадания вариант в промежуток $(x_i; x_{i+1}]$.

2) Найти эмпирическую функцию распределения $F^*(x)$.

3) На основании данного распределения, найти выборочную среднюю $\bar{x}$, несмещённую выборочную дисперсию S^{*2} , моду M_o и медиану M_e .

4) Найти доверительные интервалы для оценки, с надёжностью $\gamma_1 = 0,9$, $\gamma_2 = 0,95$ и $\gamma_3 = 0,99$, неизвестного математического ожидания $M(\xi) = a$ генеральной совокупности в предположении, что она распределена нормально.



i	1	2	3	4	5	6
$(x_i; x_{i+1}]$	$(10; 14]$	$(14; 18]$	$(18; 22]$	$(22; 26]$	$(26; 30]$	$(30; 34]$
n_i	4	11	15	12	6	2

1) Построить гистограмму относительных частот по сгруппированным данным, где n_i – частота попадания вариант в промежуток $(x_i; x_{i+1}]$.

1) Находим вектор относительных частот наблюдений, попавших в i -тый интервал $P_i^* = \frac{n_i}{n}$.

$$P^* = [4/50, 11/50, 15/50, 12/50, 6/50, 2/50] = [0.08, 0.22, 0.3, 0.24, 0.12, 0.04].$$

$$P^*/h = [0.02, 0.055, 0.075, 0.06, 0.03, 0.01].$$

Строим график гистограммы относительных частот, рис. 30.





Рис. 30. Гистограмма относительных частот

i	1	2	3	4	5	6
$(x_i; x_{i+1}]$	(10; 14]	(14; 18]	(18; 22]	(22; 26]	(26; 30]	(30; 34]
n_i	4	11	15	12	6	2

2) Находим эмпирическую функцию распределения по формуле $F^*(x) = P^*(\xi < x) = \frac{n_x}{n}$, где n_x — число наблюдений меньших x . При задании выборки в виде группового распределения, где значения частот относятся к центру интервалов, массив координат $D = [12, 16, 20, 24, 28, 32]$, функцию распределения необходимо строить в виде непрерывной ломаной кривой. Уравнение прямой проходящей через две точки с координатами (x_i, y_i) и $(x_i + \Delta x, y_i + \Delta y_i)$ записывается в виде $y = y_i + \frac{\Delta y_i}{\Delta x}(x - x_i)$. Для нашего примера $x_i = 10 + 4(i - 1)$, $i = 1, 2, 3, 4, 5, 6, 7$, а $y_1 = 0$, $y_i = y_{i-1} + P_i, i = 2, 3, \dots, 7$, т.е, массив $Y = [0, 0.08, 0.3, 0.6, 0.84, 0.96, 1]$. $\Delta y_i = [0.08, 0.22, 0.3, 0.24, 0.12, 0.04]$.

$$F^*(x) = \begin{cases} 0 & \text{при } x \leq 10, \\ 0,02(x - 10) & \text{при } x \in (10, 14], \\ 0,08 + 0,055(x - 14) & \text{при } x \in (14, 18], \\ 0,3 + 0,075(x - 18) & \text{при } x \in (18, 22], \\ 0,6 + 0,06(x - 22) & \text{при } x \in (22, 26], \\ 0,84 + 0,03(x - 26) & \text{при } x \in (26, 30], \\ 0,96 + 0,01(x - 30) & \text{при } x \in (30, 34], \\ 1 & \text{при } x > 36, \end{cases}$$



i	1	2	3	4	5	6
$(x_i; x_{i+1}]$	(10; 14]	(14; 18]	(18; 22]	(22; 26]	(26; 30]	(30; 34]
n_i	4	11	15	12	6	2

По формуле (12.4) находим выборочную среднюю $\bar{x} = \frac{1}{n} \sum_{i=1}^n n_i \cdot d_i =$
 $= \frac{1}{\varepsilon_0} (4 \cdot 12 + 11 \cdot 16 + 15 \cdot 20 + 12 \cdot 24 + 6 \cdot 28 + 2 \cdot 32) = 20,88.$

По формуле (12.11): $S^{*2} = \frac{1}{n-1} \sum_{i=1}^k n_i (x_i - \bar{x})^2 = 25,6588$ находим
 несмещённую выборочную дисперсию.

Выборочное средне квадратическое отклонение $S^* = \sqrt{S^{*2}} = 5,06545.$
 Найдем моду M_O

$$M_O = X_O + h \frac{f_{m0} - f_{m0-1}}{2f_{m0} - f_{m0-1} - f_{m0+1}}, \quad (12.17)$$

где X_O – нижнее значение модального интервала; $f_{m0}, f_{m0-1}, f_{m0+1}$ –
 значение частот в модальном интервале, предыдущем и в следующем
 интервалах, соответственно; h – размах интервала.

Для данного примера $X_O = 18, h = 4, m0 = 3, f_{m0} = 15,$
 $f_{m0-1} = 11, f_{m0+1} = 12.$ Подставляя в формулу (12.17), получаем

$$M_O = 18 + 4 \cdot \frac{15 - 12}{2 \cdot 15 - 11 - 12} = 18 + \frac{4 \cdot 3}{7} = 19,714$$



i	1	2	3	4	5	6
$(x_i; x_{i+1}]$	(10; 14]	(14; 18]	(18; 22]	(22; 26]	(26; 30]	(30; 34]
n_i	4	11	15	12	6	2

Найдем медиану M_e

$$M_e = X_O + h \frac{0,5 \sum_{k=1}^s f_k - \sum_{k=1}^{me-1} f_k}{f_{me}},$$

где X_O – нижняя граница интервала, в котором находится медиана; me – номер медианного интервала; f_{me} – значение частоты в медианном интервале.

Для данного примера $X_O = 18, h = 4, me = 3, f_{me} = 15$. Подставляя в формулу (12.17), получаем

$$M_e = 18 + 4 \frac{0,5(4 + 11 + 15 + 12 + 6 + 2) - (4 + 11)}{15} = 18 + \frac{4(25 - 15)}{15} = 20,667.$$

4) Найти доверительные интервалы для оценки с надежностью $\gamma_1 = 0,9$, $\gamma_2 = 0,95$ и $\gamma_3 = 0,99$, неизвестного математического ожидания $M(\xi) = a$ генеральной совокупности в предположении, что она распределена нормально.

Пока не рассмотрена теория. Решим на следующей лекции



4. Точечные оценки параметров распределения.

Определение 7. Точечной оценкой $\tilde{a}_n$ неизвестного параметра a распределения случайной величины ξ называется функция от наблюдений:

$$\tilde{a}_n = \tilde{a}(x_1, x_2, \dots, x_n).$$

Для изучения свойств этой оценки ее рассматривают как функцию от n независимых случайных величин $\xi_1, \xi_2, \dots, \xi_n$, имеющих такое же распределение, что и ξ .

$x_1, x_2, \dots, x_n$ в этом случае рассматриваются как наблюдения над этими случайными величинами: x_1 - полученное значение ξ_1 , x_2 - наблюдаемое значение ξ_2 и т.д.

Оценка $\tilde{a}_n$ в этом случае является случайной величиной.

Перечислим свойства точечной оценки $\tilde{a}_n$, которые могут считаться “хорошими”.

Определение 8. Оценка $\tilde{a}_n$ называется **состоятельной**, если при $n \rightarrow \infty$ она сходится по вероятности к оцениваемому параметру a :

$$\lim_{n \rightarrow \infty} P\{|\tilde{a}_n - a| < \varepsilon\} = 1 \text{ для } \forall \varepsilon > 0.$$

Определение 9. Оценка $\tilde{a}_n$ называется **несмещенной**, если ее математическое ожидание равно оцениваемому параметру a :

$$M(\tilde{a}_n) = a.$$

Определение 10. Оценка $\tilde{a}_n$ называется **эффeктивной**, если ее дисперсия наименьшая по сравнению с другими оценками.



При малых объемах выборки n для оценки дисперсии σ^2 используют **исправленную выборочную дисперсию** S^{*2} :

$$S^{*2} = \frac{n}{n-1} S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2. \quad (8)$$

Оценка S^{*2} является несмещенной, состоятельной оценкой дисперсии σ^2 .

Формула (8) позволяет вычислять S^{*2} для простой совокупности.

Для сгруппированных данных используют аналогичную формулу:

$$S^{*2} = \frac{1}{n-1} \sum_{i=1}^k n_i (x_i - \bar{x})^2. \quad (9)$$

Замечание. Исправленное СКО S^* является смещенной оценкой СКО S .

5. Интервальные оценки параметров распределения.

Наряду с рассмотренными точечными оценками, определяемыми одним числом, используют интервальные оценки неизвестных параметров, определяемые двумя числами - концами интервала, дающими вероятностную оценку сверху и снизу неизвестного параметра распределения.

Интервальные оценки целесообразно применять при малом объеме выборки, когда дисперсия точечной оценки велика, и она может сильно отличаться от оцениваемого параметра.



Определение 11. *Доверительным интервалом* для несмещенного параметра a называют интервал $(a_1; a_2)$ со случайными границами, зависящими от наблюдений: $a_1 = a_1(x_1, x_2, \dots, x_n)$, $a_2 = a_2(x_1, x_2, \dots, x_n)$, накрывающий неизвестный параметр с заданной вероятностью γ : $P(a \in (a_1, a_2)) = \gamma$.

Вероятность γ называется *доверительной вероятностью* или *надежностью* доверительного интервала.

Обычно γ задают равным 0,95; 0,99 и более.

Доверительный интервал для неизвестного математического ожидания нормального распределения при известной дисперсии имеет вид:

$$\left(\bar{x} - \tau_{\frac{\gamma}{2}} \frac{\sigma}{\sqrt{n}}; \bar{x} + \tau_{\frac{\gamma}{2}} \frac{\sigma}{\sqrt{n}} \right), \quad (10)$$

где величина $\tau_{\frac{\gamma}{2}}$ определяется из уравнения:

$$\Phi\left(\tau_{\frac{\gamma}{2}}\right) = \frac{\gamma}{2} \quad (11)$$

по таблицам функции Лапласа или с помощью компьютера, а $\bar{x}$ - выборочное среднее.

Замечание. При возрастании объема выборки n , как видно из (10), доверительный интервал уменьшается. При увеличении надежности γ увеличивается величина $\tau_{\frac{\gamma}{2}}$,

так как функция Лапласа в (11) возрастающая; следовательно, увеличивается и доверительный интервал (10).



Для получения доверительного интервала (10) заметим, что если независимые случайные величины ξ_i имеют нормальное распределение с параметрами a и σ , то среднее арифметическое

$$\bar{\xi} = \frac{\xi_1 + \xi_2 + \dots + \xi_n}{n}$$

тоже распределено нормально с параметрами:

$$M(\bar{\xi}) = a, \sigma(\bar{\xi}) = \frac{\sigma}{\sqrt{n}}.$$

Будем искать доверительный интервал для a в виде:

$$P\{|\bar{\xi} - a| < \varepsilon\} = \gamma,$$

где γ заданная доверительная вероятность.

Для определения ε воспользуемся формулой, которая в данном случае принимает вид:

$$P\{|\bar{\xi} - a| < \varepsilon\} = 2\Phi\left(\frac{\varepsilon}{\sigma/\sqrt{n}}\right).$$

Найдем ε из уравнения:

$$2\Phi\left(\frac{\varepsilon}{\sigma/\sqrt{n}}\right) = \gamma \Rightarrow \Phi\left(\frac{\varepsilon}{\sigma/\sqrt{n}}\right) = \frac{\gamma}{2} \Rightarrow \frac{\varepsilon}{\sigma/\sqrt{n}} = \tau_{\frac{\gamma}{2}} \Rightarrow \varepsilon = \tau_{\frac{\gamma}{2}} \cdot \frac{\sigma}{\sqrt{n}}.$$

С учетом полученной величины ε доверительный интервал принимает вид (10).



Пример 2. Найти доверительный интервал для неизвестного математического ожидания a нормально распределенной случайной величины со средним квадратическим отклонением $\sigma = 2$ по выборке объема $n = 64$ с выборочным средним $\bar{x} = 5,2$. Надежность доверительного интервала $\gamma = 0,95$.

Решение: В данном примере воспользуемся формулой (10). Поскольку $\gamma = 0,95$, то параметр $\tau_{\frac{\gamma}{2}}$ находим с помощью равенства:

$$\Phi\left(\tau_{\frac{\gamma}{2}}\right) = \frac{\gamma}{2} = \frac{0,95}{2} = 0,475.$$

Отсюда по таблицам функции Лапласа определим $\tau_{\frac{\gamma}{2}} = 1,96$. Тогда левая граница интервала

$$\bar{x} - \tau_{\frac{\gamma}{2}} \frac{\sigma}{\sqrt{n}} = 5,2 - 1,96 \cdot \frac{2}{\sqrt{64}} = 5,2 - 0,49 = 4,71.$$

Правая граница определяется как $5,2 + 0,49 = 5,69$.

Таким образом, доверительный интервал для математического ожидания a :

$$4,71 < a < 5,69.$$


Доверительный интервал для неизвестного математического ожидания нормального распределения при неизвестной дисперсии имеет вид:

$$\left(\bar{x} - t_{\gamma} \frac{S^*}{\sqrt{n}}; \bar{x} + t_{\gamma} \frac{S^*}{\sqrt{n}} \right) \quad (12)$$

где величина t_{γ} определяется по таблице критических точек распределения Стьюдента для $\alpha = 1 - \gamma$ и $k = n - 1$ или с помощью компьютера из уравнения для функции распределения Стьюдента $F_{st}(x)$ с $n - 1$ степенью свободы:

$$F_{st}(t_{\gamma}) = \frac{1 + \gamma}{2},$$

$\bar{x}$ и S^* соответственно выборочное среднее и исправленное СКО.

Для получения доверительного интервала примем без доказательства, что если независимые случайные величины ξ_i имеют нормальное распределение с параметрами a и σ , то случайная величина

$$t = \frac{\bar{\xi} - a}{S^*/\sqrt{n}}$$

имеет распределение Стьюдента с $k = n - 1$ степенью свободы.

Обозначим t_{γ} значение, при котором с вероятностью γ выполняется следующее неравенство:

$$P\{|t| < t_{\gamma}\} = \gamma.$$



Критические точки распределения Стьюдента

Число степеней свободы k	Уровень значимости α (двусторонняя критическая область)					
	0,10	0,05	0,02	0,01	0,002	0,001
1	6,31	12,7	31,82	63,7	318,3	637,0
2	2,92	4,30	6,97	9,92	22,33	31,6
3	2,35	3,18	4,54	5,84	10,22	12,9
4	2,13	2,78	3,75	4,60	7,17	8,61
5	2,01	2,57	3,37	4,03	5,89	6,86
6	1,94	2,45	3,14	3,71	5,21	5,96
7	1,89	2,36	3,00	3,50	4,79	5,40
8	1,86	2,31	2,90	3,36	4,50	5,04
9	1,83	2,26	2,82	3,25	4,30	4,78
10	1,81	2,23	2,76	3,17	4,14	4,59
11	1,80	2,20	2,72	3,11	4,03	4,44
12	1,78	2,18	2,68	3,05	3,93	4,32
13	1,77	2,16	2,65	3,01	3,85	4,22
14	1,76	2,14	2,62	2,98	3,79	4,14
15	1,75	2,13	2,60	2,95	3,73	4,07
16	1,75	2,12	2,58	2,92	3,69	4,01
17	1,74	2,11	2,57	2,90	3,65	3,96
18	1,73	2,10	2,55	2,88	3,61	3,92
19	1,73	2,09	2,54	2,86	3,58	3,88
20	1,73	2,09	2,53	2,85	3,55	3,85
21	1,72	2,08	2,52	2,83	3,53	3,82
22	1,72	2,07	2,51	2,82	3,51	3,79
23	1,71	2,07	2,50	2,81	3,49	3,77
24	1,71	2,06	2,49	2,80	3,47	3,74
25	1,71	2,06	2,49	2,79	3,45	3,72
26	1,71	2,06	2,48	2,78	3,44	3,71
27	1,71	2,05	2,47	2,77	3,42	3,69
28	1,70	2,05	2,46	2,76	3,40	3,66
29	1,70	2,05	2,46	2,76	3,40	3,66
30	1,70	2,04	2,46	2,75	3,39	3,65
40	1,68	2,02	2,42	2,70	3,31	3,55
60	1,67	2,00	2,39	2,66	3,23	3,46
120	1,66	1,98	2,36	2,62	3,17	3,37
∞	1,64	1,96	2,33	2,58	3,09	3,29



4) Найти доверительные интервалы для оценки с надежностью $\gamma_1 = 0,9$, $\gamma_2 = 0,95$ и $\gamma_3 = 0,99$, неизвестного математического ожидания $M(\xi) = a$ генеральной совокупности в предположении, что она распределена нормально.

Доверительный интервал для неизвестного математического ожидания нормального распределения при неизвестной дисперсии вычисляем по формуле (12.14) $\left(\bar{x} - t_\gamma \frac{S^*}{\sqrt{n}}; \bar{x} + t_\gamma \frac{S^*}{\sqrt{n}}\right)$, где величина t_γ определяется по таблице приложения 3 критических точек распределения Стьюдента для $\alpha = 1 - \gamma$ и $k = n - 1$ или с помощью компьютера из уравнения для функции распределения Стьюдента $F_{st}(x)$ с $k = n - 1 = 49$ степенью свободы. $\alpha_1 = 0,1$, $\alpha_2 = 0,05$, $\alpha_3 = 0,01$.

$$t_{\gamma_1} = 1,675; \quad t_{\gamma_2} = 2,01; \quad t_{\gamma_3} = 2,68.$$

Находим радиусы доверительных интегралов $\epsilon_i = t_{\gamma_i} \frac{S^*}{\sqrt{n}}, i = 1, 2, 3$.

$$\epsilon_1 = 1,675 \frac{5,06545}{\sqrt{50}} = 1,19991. \quad \epsilon_2 = 2,01 \frac{5,06545}{\sqrt{50}} = 1,43989. \quad \epsilon_3 = 2,68 \frac{5,06545}{\sqrt{50}} = 1,91985.$$

Находим доверительные интервалы.

$$I_1 = [19,6801; 22,0799]; \quad I_2 = [19,4401; 22,3199]; \quad I_3 = [18,9601; 22,7999].$$

$$P(19,6801 < M(\xi) < 22,0799) = 0,9.$$

$$P(19,4401 < M(\xi) < 22,3199) = 0,95.$$

$$P(18,9601 < M(\xi) < 22,7999) = 0,99.$$

С учетом четности плотности распределения Стьюдента значение t_γ определяется из условия:

$$\begin{aligned} P\{|t| < t_\gamma\} = \gamma &\Leftrightarrow P\{|t| > t_\gamma\} = 1 - \gamma \Rightarrow P\{t > t_\gamma\} = \frac{1 - \gamma}{2} \Leftrightarrow \\ &\Leftrightarrow 1 - F_{st}(t_\gamma) = \frac{1 - \gamma}{2} \Leftrightarrow F_{st}(t_\gamma) = \frac{1 + \gamma}{2}. \end{aligned}$$

Получаем:

$$P\left\{\left|\frac{\bar{\xi} - a}{S^*/\sqrt{n}}\right| < t_\gamma\right\} = \gamma \Leftrightarrow P\left\{-t_\gamma < \frac{\bar{\xi} - a}{S^*/\sqrt{n}} < t_\gamma\right\} = \gamma,$$

откуда получаем для a доверительный интервал в виде (12).

Пример 3. Найти доверительный интервал для неизвестного математического ожидания a нормально распределенной случайной величины с выборочным средним $\bar{x} = 10,5$ и исправленным СКО $S^* = 1,6$ по выборке объема $n = 16$. Надежность доверительного интервала $\gamma = 0,99$.

Решение: По таблице для числа степеней свободы $k = n - 1 = 15$ и $\alpha = 1 - \gamma = 0,01$ находим $t_\gamma = 2,98$. Подставляя полученное значение в (12) получаем искомый доверительный интервал:

$$9,308 < a < 11,692.$$

8. Критерий Пирсона проверки гипотезы о виде закона распределения.

Пусть имеется случайная выборка, состоящая из n элементов. Требуется найти закон распределения изучаемой случайной величины ξ (генеральной совокупности), определить его параметры и оценить согласие выборки с принятым законом распределения.

На основании статистического материала проверяется гипотеза H_0 , состоящая в том, что случайная величина ξ подчиняется некоторому закону распределения. Для того чтобы принять или отвергнуть гипотезу H_0 , рассматривается величина U - степень расхождения теоретического и статистического распределения. За U принимают сумму квадратов (с некоторыми коэффициентами) отклонений теоретических вероятностей P_i от соответствующих частот P_i^* (критерий χ^2).

Схема расчётов с помощью критерия Пирсона (критерия χ^2):

- 1) На основании выборки выбираем в качестве предполагаемого какой-то закон распределения изучаемой величины и оцениваем его параметры.
- 2) Всё множество наблюдений разбиваем на s интервалов вида $(a_{j-1}; a_j]$ и подсчитываем эмпирические частоты - количество наблюдений m_j , попавших в j -ый интервал. Относительная частота наблюдений, попавших в j -ый интервал, равна $P_i^* = \frac{m_j}{n}$, ($m_1 + \dots + m_s = n$), сумма всех частот, очевидно, равна единице.



3) Определяем теоретические частоты m'_j для j -го интервала $(a_{j-1}; a_j]$:

$$m'_j = (F(a_j) - F(a_{j-1})) \cdot n,$$

где $F(x)$ – теоретическая функция распределения, найденная на этапе 1.

4) Вычисляем критерий $\chi^2_{\text{наб}}$ (критерий Пирсона):

$$\chi^2_{\text{наб}} = \sum_{j=1}^s \frac{(m_j - m'_j)^2}{m'_j}. \quad (13)$$

Из этого выражения видно, что $\chi^2_{\text{наб}}$ равно нулю лишь при совпадении всех соответствующих эмпирических и теоретических частот: $m_j = m'_j$ ($j = 1, 2, \dots, s$).

В противном случае $\chi^2_{\text{наб}}$ отлично от нуля и тем больше, чем больше расхождение между частотами.

Величина $\chi^2_{\text{наб}}$, определяемая равенством (13), является случайной, и (при больших n) имеет χ^2 -распределение с k степенями свободы (принимается без доказательства).

5) Определяем число степеней свободы k случайной величины χ^2 :

$$k = s - 1 - r,$$

где r - число параметров закона распределения (для нормального закона распределения $r = 2$), s - число интервалов.

6) По заданному уровню значимости α и числу степеней свободы k по таблице критических точек распределения χ^2 (таблица приложения 4) находим критическую точку $\chi^2_{\text{кр}}(\alpha; k)$.

1. Основные понятия проверки статистических гипотез.

Определение 1. Статистической называется гипотеза о виде распределения или о значениях его параметров.

Гипотезы будем обозначать $H_0, H_1, H_2, \dots$

Различают проверяемую или основную гипотезу H_0 и альтернативную или конкурирующую H_1 , которая должна противоречить основной гипотезе.

Пример 1. Проверяемая гипотеза H_0 состоит в том, что математическое ожидание случайной величины ξ равна заданному значению a_0 .

$H_0: M(X) = a_0$. Альтернативная $H_1: M(X) > a_0$.

Для проверки статистической гипотезы на основании выборки $x_1, x_2, \dots, x_n$ вычисляют значение критерия, зависящего от наблюдений:

$$T = T(x_1, x_2, \dots, x_n).$$

Все множество значений критерия делится на так называемую критическую область, при попадании в которую критерия проверяемая гипотеза отвергается и область принятия гипотезы.

При принятии решения о справедливости гипотезы H_0 , возможны следующие ошибки:

- гипотеза H_0 отвергается, хотя на самом деле она верна (**ошибка первого рода**);
- гипотеза H_0 принимается, хотя на самом деле она не верна, а справедлива гипотеза H_1 (**ошибка второго рода**).



Определение 2. Вероятность ошибки первого рода называется **уровнем значимости** критерия и обычно обозначается α .

Определение 3. Вероятность правильно отвергнуть проверяемую гипотезу называется **мощностью критерия** и обычно обозначается β .

Заметим, что вероятность ошибки второго рода равна $1 - \beta$.

Одновременно уменьшить вероятности ошибок первого и второго рода можно только увеличив объем выборки n .

При фиксированном n обычно задают допустимый уровень ошибки первого рода α и стараются минимизировать вероятность ошибки второго рода $1 - \beta$, т.е. максимизировать мощность критерия β .

На практике при проверке статистической гипотезы на основании наблюдений вычисляют наблюдаемое значение критерия $T_{набл}$ и по заданному уровню значимости α определяют границы критической области – критические точки.

Если критическая область правосторонняя, т.е. $(t_{кр2}; +\infty)$, при выполнении условия

$T_{набл} > t_{кр2}$ делают вывод: проверяемая гипотеза H_0 отвергается с уровнем

значимости α в пользу гипотезы H_1 ; если это условие не выполняется, т.е.

$T_{набл} \leq t_{кр2}$, делают более осторожный вывод: нет оснований для того, чтобы

отвергнуть гипотезу H_0 в пользу гипотезы H_1 с уровнем значимости α .



Если критическая область левосторонняя, т.е. $(-\infty; t_{кр1})$, гипотеза H_0 отвергается при выполнении условия $T_{набл} < t_{кр1}$. В случае двусторонней критической области вида $(-\infty; t_{кр1}) \cup (t_{кр2}; +\infty)$ гипотеза H_0 отвергается при выполнении условия $T_{набл} < t_{кр1}$ или $T_{набл} > t_{кр2}$.

2. Проверка гипотезы о значимости выборочного коэффициента корреляции.

Пусть на основании данных корреляционной таблицы по выборке объёма n независимых наблюдений над нормально распределёнными случайными величинами найден выборочный коэффициент корреляции r_{xy}^* , который оказался отличным от нуля.

Так как выборка отобрана случайно, возникает вопрос о том, будет ли отличен от нуля теоретический коэффициент корреляции $r_{\xi\zeta}$, к которому сходится выборочный коэффициент при $n \rightarrow \infty$.

Необходимо при заданном уровне значимости α проверить гипотезу $H_0: r_{\xi\zeta} = 0$ при альтернативной гипотезе $H_1: r_{\xi\zeta} \neq 0$.

Если H_0 отвергается, это означает, что выборочный коэффициент корреляции значимо отличается от нуля, а случайные величины ξ и ζ коррелированы, т.е. в той или иной степени связаны линейной зависимостью. Если H_0 принимается, это означает, что выборочный коэффициент корреляции незначимо отличается от нуля, а случайные величины ξ и ζ некоррелированы, т.е. не связаны линейной зависимостью.



В качестве критерия для проверки H_0 выбирается случайная величина

$$T = r_{xy}^* \frac{\sqrt{n-2}}{\sqrt{1-r_{xy}^{*2}}}, \quad (1)$$

где r_{xy}^* - выборочный коэффициент корреляции.

При справедливости гипотезы H_0 величина T имеет так называемое распределение Стьюдента с $n-2$ степенями свободы. Критическая область для рассматриваемой гипотезы будет двусторонней, $t_{кр1} = -t_{кр2}$. Критическая точка $t_{кр2}$ определяется по заданному уровню значимости α и числу степеней $n-2$ по специальным таблицам (приложение 3) или с помощью обратной к функции распределения Стьюдента, имеющейся, например, среди статистических функций Excel для $\alpha/2$ и $n-2$ степеней свободы.

По формуле (1) для данных наблюдений определяем значение критерия $T_{набл}$.

Если $|T_{набл}| > t_{кр2}$, гипотеза H_0 отвергается с уровнем значимости α , если $|T_{набл}| \leq t_{кр2}$ - нет оснований отвергнуть H_0 .

Пример 2. С уровнем значимости $\alpha = 0,1$ проверить гипотезу о значимости выборочного коэффициента корреляции $r_{xy}^* = -0,55$, вычисленного по выборке объема $n = 60$.

Решение: Для $n = 60$ и $\alpha = 0,1$ по таблице приложения 3 для двусторонней критической области находим $t_{кр2} = 1,67$. Вычисляем наблюдаемое значение критерия по формуле (1) для $r_{xy}^* = -0,55$:



$$T_{\text{набл}} = -0,55 \cdot \frac{\sqrt{58}}{\sqrt{1-0,55^2}} \approx -5,015.$$

Поскольку $|T_{\text{набл}}| > 1,67$, делаем вывод: гипотеза H_0 отвергается с уровнем значимости $\alpha = 0,1$. Другими словами, можно довольно уверенно заявить, что коэффициент корреляции отличен от нуля.

3. Сравнение двух математических ожиданий.

Пусть имеются две независимые выборки объёмов n и m из нормальных совокупностей с известными дисперсиями σ_1^2 и σ_2^2 . Требуется по найденным выборочным средним $\bar{x}$ и $\bar{y}$ с уровнем значимости α проверить нулевую гипотезу H_0 о равенстве теоретических математических ожиданий:

$$H_0: M(\xi) = M(\zeta).$$

Заметим, что в силу несмещённости оценок $\bar{x}$ и $\bar{y}$ следует, что нулевую гипотезу можно записать и так:

$$H_0: M(\bar{\xi}) = M(\bar{\zeta}).$$

Другими словами, требуется проверить значимо или нет отличаются между собой выборочные средние. В качестве критерия проверки гипотезы примем величину:

$$Z = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}}. \quad (2)$$



Для изучения её свойств рассмотрим соответствующую случайную величину:

$$Z = \frac{\bar{\xi} - \bar{\zeta}}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}},$$

где $\bar{\xi} = \frac{\sum_{i=1}^n \xi_i}{n}$, $\bar{\zeta} = \frac{\sum_{i=1}^m \zeta_i}{m}$.

Если верна гипотеза H_0 , т.е. $\xi_i \sim N(a; \sigma_1)$, $\zeta_i \sim N(a; \sigma_2)$, то $Z \sim N(0; 1)$.

Действительно, Z является линейной комбинацией нормально распределённых случайных величин и поэтому сама распределена нормально. Её математическое ожидание и дисперсия равны:

$$M(Z) = \frac{M(\bar{\xi}) - M(\bar{\zeta})}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} = \frac{\sum_{i=1}^n M(\xi_i)/n - \sum_{i=1}^m M(\zeta_i)/m}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} = \frac{\frac{na}{n} - \frac{ma}{m}}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} = 0,$$

$$D(Z) = \frac{D(\bar{\xi}) + D(\bar{\zeta})}{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}} = \frac{\sum_{i=1}^n D(\xi_i)/n^2 + \sum_{i=1}^m D(\zeta_i)/m^2}{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}} = \frac{\frac{n\sigma_1^2}{n^2} + \frac{m\sigma_2^2}{m^2}}{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}} = 1.$$



Поэтому, в зависимости от конкурирующей гипотезы, решающее правило выглядит следующим образом:

- $H_0 : M(\xi) = M(\zeta), H_1 : M(\xi) \neq M(\zeta).$

Критическая область двусторонняя с вероятностью $\alpha/2$ попадания в каждую половину в случае справедливости H_0 . Из уравнения $F_{\text{ст}}(Z_{\text{кр}}) = 1 - \alpha/2$, где $F_{\text{ст}}(Z)$ - функция распределения стандартного нормального закона, находим значение $Z_{\text{кр}}$, вычисляем по данным наблюдениям значение критерия $Z_{\text{набл}}$ и если $|Z_{\text{набл}}| > Z_{\text{кр}}$, то отвергаем гипотезу H_0 с уровнем значимости α . Если $|Z_{\text{набл}}| \leq Z_{\text{кр}}$, у нас нет оснований отвергнуть гипотезу H_0 в пользу данной гипотезы H_1 .

На практике уравнение $F_{\text{ст}}(Z_{\text{кр}}) = 1 - \alpha/2$ решают или с помощью ЭВМ (например, Excel), или по таблице приложения 2 и уравнения (3):

$$\begin{aligned} F_{\text{ст}}(Z_{\text{кр}}) = \Phi(Z_{\text{кр}}) + 0,5 &\Rightarrow F_{\text{ст}}(Z_{\text{кр}}) = 1 - \alpha/2 \Leftrightarrow \\ &\Leftrightarrow \Phi(Z_{\text{кр}}) + 0,5 = 1 - \alpha/2 \Leftrightarrow \\ \Phi(Z_{\text{кр}}) &= \frac{1}{2} - \frac{\alpha}{2}; \end{aligned} \quad (3)$$

- $H_0 : M(\xi) = M(\zeta), H_2 : M(\xi) > M(\zeta).$

Критическая область правосторонняя с вероятностью α попадания в неё в случае справедливости H_0 .



Из уравнения $F_{\text{ст}}(Z_{\text{кр}}) = 1 - \alpha$ находим значение $Z_{\text{кр}}$, вычисляем по формуле (2) $Z_{\text{набл}}$ и если $Z_{\text{набл}} > Z_{\text{кр}}$, то отвергаем гипотезу H_0 с уровнем значимости α . Если $Z_{\text{набл}} \leq Z_{\text{кр}}$, то нет оснований отвергнуть гипотезу H_0 . На практике $Z_{\text{кр}}$ находят или с помощью ЭВМ или по таблице приложения 2, из уравнения (4):

$$F_{\text{ст}}(Z_{\text{кр}}) = 1 - \alpha \Leftrightarrow \Phi(Z_{\text{кр}}) + 0,5 = 1 - \alpha \Leftrightarrow \Phi(Z_{\text{кр}}) = \frac{1}{2} - \alpha; \quad (4)$$

- $H_0: M(\xi) = M(\zeta), \quad H_3: M(\xi) < M(\zeta).$

Критическая область левосторонняя с вероятностью α попадания в неё в случае справедливости H_0 . Из уравнения $F_{\text{ст}}(Z'_{\text{кр}}) = \alpha$ находим значение $Z'_{\text{кр}}$.

В силу симметрии нормального распределения относительно нуля на практике находят значение $Z_{\text{кр}}$ из уравнения (4) и берут $Z'_{\text{кр}} = -Z_{\text{кр}}$. Если $Z_{\text{набл}} < -Z_{\text{кр}}$, гипотезу H_0 отвергают с уровнем значимости α , если $Z_{\text{набл}} \geq -Z_{\text{кр}}$, то нет оснований отвергнуть H_0 .

Замечание 1. Если независимые выборки достаточно большие, указанный критерий можно применять для случая неизвестных дисперсий и не обязательно нормального распределения совокупностей. В этом случае вместо формулы (2) используют формулу (5) для вычисления критерия Крамера-Уэлча:

$$Z = \frac{x - y}{\sqrt{\frac{S_1^{*2}}{n} + \frac{S_2^{*2}}{m}}}. \quad (5)$$



4. Сравнение математического ожидания с заданным значением.

Пусть имеется выборка объема n нормальной совокупности с известной дисперсией σ^2 . Требуется по найденной выборочной средней с уровнем значимости α проверить гипотезу H_0 о равенстве неизвестного математического ожидания $M(\xi)$ заданному значению a_0 :

$$H_0: M(\xi) = a_0.$$

В силу несмещенности оценки $\bar{x}$ заключаем, что нулевую гипотезу можно записать и так:

$$H_0: M(\bar{\xi}) = a_0.$$

Другими словами, требуется проверить, значимо или нет отличается выборочное среднее от заданного значения. В качестве критерия выберем величину

$$U = \frac{\bar{x} - a_0}{\sigma/\sqrt{n}} = \frac{\bar{x} - a_0}{\sigma} \cdot \sqrt{n} \quad (6)$$

Можно доказать (сделайте это самостоятельно), что соответствующая случайная величина $U = \frac{\bar{\xi} - a_0}{\sigma/\sqrt{n}}$ имеет стандартное нормальное распределение. Поэтому в зависимости от конкурирующей гипотезы, решающее правило будет следующим:

- $H_0 : M(\xi) = a_0; \quad H_1 : M(\xi) \neq a_0.$

Из уравнения (3) по таблице приложения 2 (или с помощью ЭВМ) определяем $Z_{кр}$, по формуле (6) находим $U_{набл}$ для имеющихся наблюдений.



Если $|U_{\text{набл}}| > Z_{\text{кр}}$, гипотезу H_0 отвергаем с уровнем значимости α , если $|U_{\text{набл}}| \leq Z_{\text{кр}}$, то нет оснований отвергнуть гипотезу H_0 в пользу данной гипотезы H_1 .

- $H_0 : M(\xi) = a_0; \quad H_2 : M(\xi) > a_0.$

Из уравнения (4) определяем $Z_{\text{кр}}$, по формуле (6) находим $U_{\text{набл}}$. Если $U_{\text{набл}} > Z_{\text{кр}}$, гипотезу H_0 отвергаем с уровнем значимости α , если $U_{\text{набл}} \leq Z_{\text{кр}}$, то нет оснований отвергнуть H_0 .

- $H_0 : M(\xi) = a_0; \quad H_3 : M(\xi) < a_0.$

Из уравнения (4) определяем $Z_{\text{кр}}$, по формуле (6) находим $U_{\text{набл}}$. Если $U_{\text{набл}} < -Z_{\text{кр}}$, гипотезу H_0 отвергаем с уровнем значимости α , если $U_{\text{набл}} \geq -Z_{\text{кр}}$, то нет оснований отвергнуть H_0 .

Если в условиях дисперсия неизвестна, в качестве критерия следует выбрать величину

$$T = \frac{\bar{x} - a_0}{S^*/\sqrt{n}} = \frac{\bar{x} - a_0}{S^*} \cdot \sqrt{n} \quad (7)$$

Можно доказать (мы не будем этого делать), что соответствующая случайная величина $T = \frac{\bar{\xi} - a_0}{S^*} \cdot \sqrt{n}$ имеет распределение Стьюдента с $n-1$ степенью свободы.

Решающее правило в зависимости от конкурирующей гипотезы будет следующим:



- $H_0 : M(\xi) = a_0; \quad H_1 : M(\xi) \neq a_0.$

Критическая область в данном случае будет двусторонней; критическая точка t_2 определяется по заданным α и $n-1$ по специальным таблицам (приложение 3) или с помощью функции обратной к функции распределения Стьюдента, имеющейся, например, среди статистических функций Excel. По формуле (7) определяем $T_{\text{набл}}$. Если $|T_{\text{набл}}| > t_2$, гипотеза H_0 отвергается с уровнем значимости α , если $|T_{\text{набл}}| \leq t_2$, то нет оснований отвергнуть H_0 в пользу данной гипотезы H_1 .

При конкурирующих гипотезах $H_2 : M(\xi) > a_0$ и $H_3 : M(\xi) < a_0$ строят соответственно правостороннюю и левостороннюю критические области.

5. Сравнение вероятности с заданным значением.

Пусть проведено n независимых испытаний Бернулли с неизвестной вероятностью p появления события A в каждом. По результатам испытаний найдена

относительная частота $\frac{m}{n}$, где m - число появлений события A в n испытаниях.

Требуется по величине $\frac{m}{n}$ с уровнем значимости α проверить нулевую гипотезу

H_0 о том, что неизвестная вероятность p равна заданному значению p_0 :

$$H_0 : p = p_0.$$

Заметим, что в силу несмещенности оценки $\frac{m}{n}$ для p нулевую гипотезу можно

записать и так:

$$H_0 : M\left(\frac{m}{n}\right) = p_0.$$



Другими словами, требуется проверить, значимо или нет отличается частота от значений p_0 . В качестве критерия проверки гипотезы примем величину

$$U = \frac{\frac{m}{n} - p_0}{\sqrt{p_0 q_0}} \cdot \sqrt{n}, \quad (8)$$

где $q_0 = 1 - p_0$.

Соответствующая случайная величина при справедливости гипотезы H_0 имеет стандартное нормальное распределение. При этом рассуждения аналогичны приведенным в пункте 4 для случая известной дисперсии, с учётом того, что

$$M\left(\frac{m}{n}\right) = p_0, \quad D\left(\frac{m}{n}\right) = \frac{p_0 q_0}{n}.$$

В зависимости от конкурирующей гипотезы решающее правило будет таким же, как в пункте 4 для случая известной дисперсии, но значение $U_{\text{набл}}$, конечно, следует вычислять по формуле (8).

6. Сравнение двух дисперсий (критерий Фишера).

Пусть по независимым выборкам объёмов n_1 и n_2 из нормальных совокупностей найдены исправленные выборочные дисперсии S_1^{*2} и S_2^{*2} , причём S_1^{*2} - большая из них. Требуется при заданном уровне значимости α проверить нулевую гипотезу H_0 о равенстве теоретических дисперсий:

$$H_0: \sigma_1^2 = \sigma_2^2.$$



Заметим, что в силу несмещенности оценок S_1^{*2} и S_2^{*2} нулевую гипотезу можно записать и так:

$$H_0: M(S_1^{*2}) = M(S_2^{*2}).$$

В качестве критерия проверки гипотезы примем отношение большей исправленной дисперсии к меньшей:

$$F = \frac{S_1^{*2}}{S_2^{*2}}.$$

Известно, что при условии справедливости нулевой гипотезы, величина F имеет распределение Фишера-Снедекора со степенями свободы $k_1 = n_1 - 1$, $k_2 = n_2 - 1$.

Решающее правило зависит от конкурирующей гипотезы.

$$\bullet H_0: \sigma_1^2 = \sigma_2^2, \quad H_1: \sigma_1^2 > \sigma_2^2.$$

В этом случае строят правостороннюю критическую область, исходя из того, что при справедливости H_0 ($\sigma_1^2 = \sigma_2^2$) вероятность больших значений F мала:

$$P\{F > t_2(\alpha; k_1; k_2)\} = \alpha.$$

Критическую точку $t_2(\alpha; k_1; k_2)$ находят по таблице критических точек распределения Фишера–Снедекора (приложение 5) или, например, с помощью обратной функции F – распределения среди статистических функций Excel.

Если $F_{\text{набл}} > t_2(\alpha; k_1; k_2)$, гипотезу H_0 отвергают с уровнем значимости α .



$$\bullet H_0: \sigma_1^2 = \sigma_2^2, \quad H_2: \sigma_1^2 \neq \sigma_2^2.$$

В этом случае строят двустороннюю критическую область так, чтобы вероятности попадания в левую и правую половину были бы равны $\alpha/2$:

$$P\{F < t_1(\alpha/2; k_1; k_2)\} = P\{F > t_2(\alpha/2; k_1; k_2)\} = \frac{\alpha}{2}.$$

Критическую точку $t_2(\alpha/2; k_1; k_2)$ находят по таблице приложения 5 или с помощью ЭВМ. Если $F_{\text{набл}} > t_2(\alpha/2; k_1; k_2)$, гипотезу H_0 отвергают с уровнем значимости α .

$$\bullet H_0: \sigma_1^2 = \sigma_2^2, \quad H_3: \sigma_1^2 < \sigma_2^2.$$

Поскольку $S_1^{*2} > S_2^{*2}$, без дополнительного исследования ясно, что при конкурирующей гипотезе H_3 гипотеза H_0 предпочтительнее. Этот случай очевиден.

Пример 3. По двум независимым выборкам из нормальных генеральных совокупностей, объёмы которых равны $n_1 = 12$ и $n_2 = 15$, найдены исправленные выборочные дисперсии $S_1^{*2} = 10$, $S_2^{*2} = 5,5$. С уровнем значимости $\alpha = 0,05$ проверить нулевую гипотезу о равенстве дисперсий $H_0: \sigma_1^2 = \sigma_2^2$ при конкурирующей гипотезе $H_1: \sigma_1^2 > \sigma_2^2$.

Решение: В данном примере $k_1 = 12 - 1 = 11$, $k_2 = 15 - 1 = 14$, $F_{\text{набл}} = \frac{S_1^{*2}}{S_2^{*2}} = 1,82$.

Выбираем среди статистических функций Excel обратное F – распределение и находим $t_2(0,05; 11; 14) = 2,56$. Так как $F_{\text{набл}} < t_2(\alpha; k_1; k_2)$, то нет оснований отвергнуть нулевую гипотезу о равенстве дисперсий.



РТУ МИРЭА

Кафедра высшая математика 3



Теория вероятностей и математическая
статистика

Лекция 7

Основные понятия математической статистики

Для студентов ИИТ

Берков Николай Андреевич

10 мая 2024г

Спасибо за внимание