



Теория вероятностей и математическая статистика

Лектор: Егорова Алена Андреевна, к.ф.-м.н, доцент
кафедры Высшей математики -3 ИПТИП

e-mail: egorova@mirea.ru



Лекция №8. Введение в математическую статистику.

Выборочное распределение.

Определения. Эмпирической (статистической) функцией распределения по случайной выборке называется функция $F_n^*(x) = \frac{v_n(x)}{n}$, где $v_n(x)$ - число значений в выборке меньших x .

Теорема 1.1 (Гливенко-Кантелли). Пусть $F(x)$ — функция распределения вероятности случайной величины ξ , а $F_n^*(x)$ — эмпирическая функция распределения вероятности, построенная по случайной выборке объема n . Тогда для любого $\varepsilon > 0$

$$\lim_{n \rightarrow \infty} P\{|F_n^*(x) - F(x)| < \varepsilon\} = 1.$$

Определения. Медиана M_e — значение варианта, для которого количество элементов находящихся слева и справа (меньших его и больших его), одинаково.

Определения. Модой M_o называется значение варианта, который имеет наибольшую частоту по сравнению с другими частотами.

Пример 1. Выборка задана в виде распределения частот (см. таблицу). Найти объем, размах, моду, медиану и эмпирическую функцию распределения.

$$F_n^*(M_e) = 0,5$$

или:

$$M_e = \begin{cases} X_{\frac{n+1}{2}}, & \text{если } n \text{ — нечетное} \\ \frac{1}{2}(X_{\frac{n}{2}} + X_{\frac{n}{2}+1}), & \text{если } n \text{ — четное} \end{cases}$$

M_o : частота(M_o) — max.

X_i	70	71	72	73	74
m_i	2	4	8	2	4

Гистограмма.

Построение гистограммы:

1) Находим интервал $[a, b]$, содержащий все варианты значений и выборки:

$$a \leq X_i \leq b, \quad i = 1, 2, \dots, n. \quad (n - \text{объем выборки})$$

2) Разбиваем отрезок $[a, b]$ на m не пересекающихся интервалов:

$$[a, b] = \bigcup_{i=1}^{m-1} [a_i, a_{i+1}), \quad a_1 = a, \quad a_m = b, \quad h_i = a_{i+1} - a_i - \text{длины интервалов.}$$

3) Для каждого интервала $[a_i, a_{i+1})$ определяем количество чисел из случайной выборки, которые принадлежат этому интервалу и делим на объем выборки, эти числа обозначим

$$P_i^* \quad (\sum_{i=1}^m P_i^* = 1)$$

4) Строим график из прямоугольников шириной h_i и высотой

$$\frac{P_i^*}{h_i}. \quad \text{Площадь полученной фигуры равна 1.}$$




Рисунок 52. Гистограмма

Пример 2. Для данного статистического ряда начертить гистограмму на отрезке $[70; 75]$ с шагом 1.

X_i	70	70,5	71	71,8	72	72,4	72,6	73	74	74,5
m_i	1	1	3	1	5	2	1	2	2	2

Выборочные моменты. Несмещенная оценка.

1. Выборочное среднее:

- является *несмещенной* оценкой математического ожидания

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^k X_i m_i$$

2. Выборочная дисперсия:

- является *смещенной* оценкой дисперсии

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$S^2 = \frac{1}{n} \sum_{i=1}^k m_i X_i^2 - (\bar{X})^2 = \frac{1}{n} \sum_{i=1}^k m_i (X_i - \bar{X})^2$$

3. Выборочное среднеквадратичное отклонение(СКО):

$$S = \sqrt{S^2}$$

$$MS^2 = \frac{n-1}{n} D\xi;$$

4. Исправленное (несмещенная) выборочная дисперсия :

- является *несмещенной* оценкой дисперсии

$$S^{*2} = \frac{n}{n-1} S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Пусть величина $\bar{X}$ построена по случайной выборке независимых значений X_i случайной величины ξ (генеральная совокупность), тогда $\bar{X}$ сама является случайной величиной, при этом:

$$M\bar{X} = M\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n MX_i = M\xi; \quad D\bar{X} = D\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n DX_i = \frac{D\xi}{n}.$$

Математическое ожидание и дисперсия являются параметрами функции распределения случайной величины, а их выборочные моменты – оценки этих параметров. Пусть некоторый параметр θ оценивается через выборочную оценку $\hat{\theta}_n$ по случайной выборке объема n .

Определение. Оценка $\hat{\theta}_n$ называется **несмещенной**, если при любом n $M\hat{\theta}_n = \theta$.



Пример 3. Выборка задана в виде распределения частот (см. таблицу). Найти выборочное среднее, выборочную дисперсию, исправленную дисперсию.

X_i	70	71	72	73	74
m_i	2	4	8	2	4

$$\bar{X} = \frac{1}{n} \sum_{i=1}^k X_i m_i$$

$$S^2 = \frac{1}{n} \sum_{i=1}^k m_i X_i^2 - (\bar{X})^2$$

$$S^{*2} = \frac{n}{n-1} S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Интервальный ряд.

Если данных достаточно много или различия между вариантами незначительны, то статистический ряд представляют в виде *интервального ряда* – таблицы с группированными по интервалам данными, с количеством вариантов, входящих в данный интервал:

i	1	2	3	4	5	6
$(x_i; x_{i+1}]$	(10; 14]	(14; 18]	(18; 22]	(22; 26]	(26; 30]	(30; 34]
m_i	4	11	15	12	6	2

- $n = \sum_{i=1}^k m_i$ - объем выборки
- $R = x_{max} - x_{min}$ - размах выборки

- Эмпирическая функция распределения

$$F^*(x) = P^*(\xi < x) = \frac{m_x}{n}$$

Пусть $d_i = \frac{(x_i + x_{i+1})}{2}$, $i = 1, 2, \dots, n$. середины интервалов.

- Выборочная средняя: $\bar{x} = \frac{1}{n} \sum_{i=1}^k m_i d_i$
- Выборочная дисперсия: $S^2 = \overline{x^2} - (\bar{x})^2$, $\overline{x^2} = \frac{1}{n} \sum_{i=1}^k m_i \cdot d_i^2$
- Несмещенная выборочная дисперсия: $S^{*2} = \frac{n}{n-1} S^2$




Рисунок 53. Функция распределения $F^*(x)$

Нахождение моды и медианы в интервальном ряде.

- **Нахождение моды.**

- 1) Находим модальный интервал $(x_{mo}; x_{mo+1}]$ интервал с наибольшей частотой m_{mo} .
- 2) Находим моду по формуле:

$$M_o = x_{mo} - h \frac{(m_{mo} - m_{mo-1})}{m_{mo-1} - 2m_{mo} + m_{mo+1}},$$

где x_{mo} - нижняя граница модального интервала, m_{mo} - значение частоты в модальном интервале, h - длина модального интервала.

- **Нахождение медианы.**

- 1) Находим медианный интервал $(x_{me}; x_{me+1}]$ - интервал соответствующий равенству $F^*(M_e) = 1/2$;
- 2) Значение медианы находим по формуле:

$$M_e = x_{me} + h \frac{(0,5 \sum_{i=1}^k m_i - \sum_{i=1}^{i_{me}-1} m_i)}{m_{me}}$$

где x_{me} - нижняя граница медианного интервала, m_{me} - значение частоты в медианном интервале, h - длина медианного интервала




Рисунок 52. Гистограмма

Состоятельные оценки.

Определение. Оценка $\hat{\theta}_n$ называется *состоятельной* оценкой параметра θ , если для любого $\varepsilon > 0$

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \varepsilon) = 1.$$

- Можно показать, что выборочное среднее $\bar{X}$ и выборочная дисперсия S^2 являются *состоятельными* оценками.

Эффективные оценки.

Определение. Оценка θ_n^* из класса оценок $K = \{\hat{\theta}_n\}$ называется *эффективной* оценкой параметра θ в классе K , если для любой другой оценки $\hat{\theta}_n \in K$

$$M(\theta_n^* - \theta)^2 \leq M(\hat{\theta}_n - \theta)^2.$$

Асимптотически нормальные оценки.

Определение. Оценка $\hat{\theta}_n$ называется *асимптотически нормальной* оценкой параметра θ , если

$$\lim_{n \rightarrow \infty} P(\sqrt{n}(\hat{\theta}_n - \theta) < x) = \frac{1}{\sigma(\theta)\sqrt{2\pi}} \int_0^x e^{-\frac{t^2}{2\sigma^2(\theta)}} dt$$

$$\text{или } \sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow[n \rightarrow \infty]{d} \zeta \sim N(0, \sigma(\theta)).$$

- Выборочное среднее $\bar{X}$ является асимптотически нормальной оценкой математического ожидания.

Метод наибольшего правдоподобия.

Пусть ξ – генеральная совокупность (случайная величина, из значений которой берется выборка) и известна ее функция распределения с точностью до неизвестного параметра θ :

$$\xi \sim F(x, \theta), \quad \theta \in [\theta_1, \theta_2].$$

Задача: Надо выбрать параметр θ так, чтобы он в наибольшей мере соответствовал случайной выборке $X_{[n]} = (X_1, X_2, \dots, X_n)$.

1. Составляем функцию правдоподобия:

Если ξ - ДСВ с законом распределения $P(\xi = X_i, \theta)$, то
$$L = L(X_1, X_2, \dots, X_n, \theta) = \prod_{i=1}^n P(\xi = X_i, \theta)$$

Если ξ - НСВ с плотностью распределения $f(x, \theta)$, то
$$L = L(X_1, X_2, \dots, X_n, \theta) = \prod_{i=1}^n f(X_i, \theta)$$

2. Ищем значение параметра θ , при котором

$$L(X_1, X_2, \dots, X_n, \theta) \rightarrow \max$$

Решаем уравнение:

$$\frac{dL}{d\theta} = 0$$



$$\ln L((X_1, X_2, \dots, X_n, \theta) \rightarrow \max$$



$$\frac{d(\ln L)}{d\theta} = 0$$

- Оценки полученные методом наибольшего правдоподобия являются *состоятельными, асимптотически эффективными и асимптотически нормальными*.

Пример 4. Методом наибольшего правдоподобия найти оценку параметра λ для г.с. ξ , имеющей распределение Пуассона.

Доверительные интервалы.



Джон фон Нейман
(1903-1957)

Точечный подход оценки параметра может предоставить некоторое приближенное значение данного параметра, но этот подход не показывает насколько значение оценки близко к истинному значению параметра. Интервальный подход был предложен Дж.Нейманом.

Пусть ξ - генеральная совокупность с функцией распределения $F_\xi(x, \theta)$, где θ – неизвестный параметр распределения. $X_{[n]} = (X_1, X_2, \dots, X_n)$ выборка из г.с. ξ .

Определение. Пусть для некоторого $\gamma \in (0,1)$ существуют статистики $a_1 = a_1(X_{[n]}, \alpha)$, $a_2 = a_2(X_{[n]}, \alpha)$ такие, что

$$P(a_1 < \theta < a_2) = \gamma,$$

тогда интервал (a_1, a_2) называется *доверительным интервалом* для параметра θ с уровнем доверия γ .

Доверительный интервал для неизвестного математического ожидания a нормального распределения при известной дисперсии σ :

$$P\left(\bar{X} - \tau_{\frac{\gamma}{2}} \frac{\sigma}{\sqrt{n}} < a < \bar{X} + \tau_{\frac{\gamma}{2}} \frac{\sigma}{\sqrt{n}}\right) = \gamma,$$

где величина $\tau_{\frac{\gamma}{2}}$ определяется из таблицы значений функции Лапласа:


$$\Phi(\tau_{\gamma/2}) = \frac{\gamma}{2}$$

Доверительный интервал для неизвестного математического ожидания a нормального распределения при неизвестной дисперсии.

Определение. Если независимые случайные величины $\xi_i \sim N(a; \sigma)$, $i = 1, \dots, n$, то случайная величина

$$t = \frac{\bar{\xi} - a}{S^*/\sqrt{n}}$$

имеет распределение Стьюдента с $n - 1$ степенью свободы.



Уильям Сили Госсет
(1876-1937)

Доверительный интервал для неизвестного математического ожидания a нормального распределения при неизвестной дисперсии имеет вид:

$$P\left(\bar{X} - t_\gamma \frac{S^*}{\sqrt{n}} < a < \bar{X} + t_\gamma \frac{S^*}{\sqrt{n}}\right) = \gamma,$$

где величина t_γ определяется из таблицы критических значений распределения Стьюдента для $\alpha = 1 - \gamma$ и $k = n - 1$ или с помощью функции распределения Стьюдента $F_{st}(x)$ с $n - 1$ степенью свободы:

$$F_{st}(t_\gamma) = \frac{1 + \gamma}{2}.$$

Пример построения доверительного интервала.

Пример 5. Рассмотрим случайную величину – рост мужчин. Построить 95% -й доверительный интервал для среднего роста мужчин, если среднеквадратичное отклонение равно 7 см и дана следующая выборка:

$X_{[20]}$:

174.83	172.75	158.51	182.70	175.53
161.66	182.38	185.49	174.96	172.73
180.90	169.08	179.66	174.01	166.57
168.18	163.92	174.85	180.21	176.37

$$I_\gamma \left(\bar{x} - \tau_{\frac{\gamma}{2}} \frac{\sigma}{\sqrt{n}}; \bar{x} + \tau_{\frac{\gamma}{2}} \frac{\sigma}{\sqrt{n}} \right),$$

$$\Phi(\tau_{\frac{\gamma}{2}}) = \frac{\gamma}{2}$$



$$\bar{X} = 173.76, \quad \sigma = 7, \quad n = 20$$

$$P\{170.70 < a < 176.83\} = 0.95$$





Таблица значений функции $\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_0^x e^{-z^2/2} dz$

x	$\Phi(x)$	x	$\Phi(x)$	x	$\Phi(x)$	x	$\Phi(x)$
0,00	0,0000	0,32	0,1255	0,64	0,2389	0,96	0,3315
0,01	0,0040	0,33	0,1293	0,65	0,2422	0,97	0,3340
0,02	0,0080	0,34	0,1331	0,66	0,2454	0,98	0,3365
0,03	0,0120	0,35	0,1368	0,67	0,2486	0,99	0,3389
0,04	0,0160	0,36	0,1406	0,68	0,2517	1,00	0,3413
0,05	0,0199	0,37	0,1443	0,69	0,2549	1,01	0,3438
0,06	0,0239	0,38	0,1480	0,70	0,2580	1,02	0,3461
0,07	0,0279	0,39	0,1517	0,71	0,2611	1,03	0,3485
0,08	0,0319	0,40	0,1554	0,72	0,2642	1,04	0,3508
0,09	0,0359	0,41	0,1591	0,73	0,2673	1,05	0,3531
0,10	0,0398	0,42	0,1628	0,74	0,2703	1,06	0,3554
0,11	0,0438	0,43	0,1664	0,75	0,2734	1,07	0,3577
0,12	0,0478	0,44	0,1700	0,76	0,2764	1,08	0,3599
0,13	0,0517	0,45	0,1736	0,77	0,2794	1,09	0,3621
0,14	0,0557	0,46	0,1772	0,78	0,2823	1,10	0,3643
0,15	0,0596	0,47	0,1808	0,79	0,2852	1,11	0,3665
0,16	0,0636	0,48	0,1844	0,80	0,2881	1,12	0,3686
0,17	0,0675	0,49	0,1879	0,81	0,2910	1,13	0,3708
0,18	0,0714	0,50	0,1915	0,82	0,2939	1,14	0,3729
0,19	0,0753	0,51	0,1950	0,83	0,2967	1,15	0,3749
0,20	0,0793	0,52	0,1985	0,84	0,2995	1,16	0,3770
0,21	0,0832	0,53	0,2019	0,85	0,3023	1,17	0,3790
0,22	0,0871	0,54	0,2054	0,86	0,3051	1,18	0,3810
0,23	0,0910	0,55	0,2088	0,87	0,3078	1,19	0,3830
0,24	0,0948	0,56	0,2123	0,88	0,3106	1,20	0,3849
0,25	0,0987	0,57	0,2157	0,89	0,3133	1,21	0,3869
0,26	0,1026	0,58	0,2190	0,90	0,3159	1,22	0,3883
0,27	0,1064	0,59	0,2224	0,91	0,3186	1,23	0,3907
0,28	0,1103	0,60	0,2257	0,92	0,3212	1,24	0,3925
0,29	0,1141	0,61	0,2291	0,93	0,3238	1,25	0,3944
0,30	0,1179	0,62	0,2324	0,94	0,3264		
0,31	0,1217	0,63	0,2357	0,95	0,3289		

$$\Phi(-x) = -\Phi(x)$$



x	$\Phi(x)$	x	$\Phi(x)$	x	$\Phi(x)$	x	$\Phi(x)$
1,26	0,3962	1,59	0,4441	1,92	0,4726	2,50	0,4938
1,27	0,3980	1,60	0,4452	1,93	0,4732	2,52	0,4941
1,28	0,3997	1,61	0,4463	1,94	0,4738	2,54	0,4945
1,29	0,4015	1,62	0,4474	1,95	0,4744	2,56	0,4948
1,30	0,4032	1,63	0,4484	1,96	0,4750	2,58	0,4951
1,31	0,4049	1,64	0,4495	1,97	0,4756	2,60	0,4953
1,32	0,4066	1,65	0,4505	1,98	0,4761	2,62	0,4956
1,33	0,4082	1,66	0,4515	1,99	0,4767	2,64	0,4959
1,34	0,4099	1,67	0,4525	2,00	0,4772	2,66	0,4961
1,35	0,4115	1,68	0,4535	2,02	0,4783	2,68	0,4963
1,36	0,4131	1,69	0,4545	2,04	0,4793	2,70	0,4965
1,37	0,4147	1,70	0,4554	2,06	0,4803	2,72	0,4967
1,38	0,4162	1,71	0,4564	2,08	0,4812	2,74	0,4969
1,39	0,4177	1,72	0,4573	2,10	0,4821	2,76	0,4971
1,40	0,4192	1,73	0,4582	2,12	0,4830	2,78	0,4973
1,41	0,4207	1,74	0,4591	2,14	0,4838	2,80	0,4974
1,42	0,4222	1,75	0,4599	2,16	0,4846	2,82	0,4976
1,43	0,4236	1,76	0,4608	2,18	0,4854	2,84	0,4977
1,44	0,4251	1,77	0,4616	2,20	0,4861	2,86	0,4979
1,45	0,4265	1,78	0,4625	2,22	0,4868	2,88	0,4980
1,46	0,4279	1,79	0,4633	2,24	0,4875	2,90	0,4981
1,47	0,4292	1,80	0,4641	2,26	0,4881	2,92	0,4982
1,48	0,4306	1,81	0,4649	2,28	0,4887	2,94	0,4984
1,49	0,4319	1,82	0,4656	2,30	0,4893	2,96	0,4985
1,50	0,4332	1,83	0,4664	2,32	0,4898	2,98	0,4986
1,51	0,4345	1,84	0,4671	2,34	0,4904	3,00	0,49865
1,52	0,4357	1,85	0,4678	2,36	0,4909	3,20	0,49931
1,53	0,4370	1,86	0,4686	2,38	0,4913	3,40	0,49966
1,54	0,4382	1,87	0,4693	2,40	0,4918	3,60	0,499841
1,55	0,4394	1,88	0,4699	2,42	0,4922	3,80	0,499928
1,56	0,4406	1,89	0,4706	2,44	0,4927	4,00	0,499968
1,57	0,4418	1,90	0,4713	2,46	0,4931	4,50	0,499997
1,58	0,4429	1,91	0,4719	2,48	0,4934	5,00	0,499997

Линейная регрессия.

Понятие регрессии означает восстановление функциональной зависимости между множеством пар переменных. В случае линейной регрессии речь идет о восстановлении линейной зависимости.

Пусть имеется набор пар двух числовых данных: $(x_t, y_t), t = 1, 2, \dots, n$. Задача линейной регрессии состоит в том, чтобы найти параметры a и b линейной зависимости

$$y = ax + b,$$

которая будет в каком-либо смысле наилучшим образом приближать исходные данные (x_t, y_t) .

Приближение будем строить *методом наименьших квадратов*: найти такие параметры a и b , чтобы минимизировать следующую функцию:

$$F(a, b) = \sum_{t=1}^n (y_t - (ax_t + b))^2 \rightarrow \min$$

$$\frac{\partial F}{\partial a} = -2 \sum_{t=1}^n x_t (y_t - ax_t - b) = 0.$$

$$\frac{\partial F}{\partial b} = -2 \sum_{t=1}^n (y_t - ax_t - b) = 0.$$



$$a = \frac{n \sum_{t=1}^n x_t y_t - \left(\sum_{t=1}^n x_t \right) \left(\sum_{t=1}^n y_t \right)}{n \sum_{t=1}^n x_t^2 - \left(\sum_{t=1}^n x_t \right)^2},$$

$$b = \frac{1}{n} \sum_{t=1}^n y_t - \frac{1}{n} \sum_{t=1}^n x_t a.$$

$$\hat{y}_t = ax_t + b,$$

$$\bar{x} = \frac{1}{n} \sum_{t=1}^n x_t,$$

$$\bar{y} = \frac{1}{n} \sum_{t=1}^n y_t.$$

$$\sum_{t=1}^n (y_t - \bar{y})^2 = \sum_{t=1}^n (y_t - \hat{y}_t)^2 + \sum_{t=1}^n (\hat{y}_t - \bar{y})^2.$$




$$TSS = ESS + RSS,$$

$$R^2 = 1 - \frac{ESS}{TSS} = \frac{RSS}{TSS}.$$

- показатель регрессии

$R = 0 \Rightarrow$ регрессия не дает информации
 $R = 1 \Rightarrow$ есть линейная зависимость между компонентами (x_t, y_t)




Проверка гипотез.

Пусть есть статистическая выборка X , некоторая гипотеза H_0 закона распределения г.с., соответствующей X . Эта гипотеза может быть истинным или ложным в зависимости от выборки.

H_0 - *основная гипотеза*. H_1 - *альтернативная гипотеза*: H_1 - истинна, когда H_0 - ложная. Правило на основании которого выбирается или отклоняется гипотеза называется *статистическим критерием*.

Вариант 1.



[Если $X \in X_0$, то принимается H_0
Если $X \in X_1$, то H_0 отвергается, а H_1 — принимается

Вариант 2. Общий принцип принятия статистических решений.

Пусть $\alpha > 0$ некоторое малое число. Если выборка X соответствует маловероятному событию с точки зрения гипотезы H_0 , то гипотеза H_0 должна быть отвергнута, как не согласуемая с данными. Т.е. основная гипотеза H_0 принимается, если

$$P(X \in X_1 | H_0) \leq \alpha.$$

В этом случае говорят, что критерий имеет уровень значимости α .

Проверка гипотез.

Критерий согласия Колмогорова.

H_0 - выборка X_n взята из г.с. ξ , которая имеет функцию распределения $F(x)$.
Пусть по выборке X_n построена эмпирическая функция распределения $F_n^*(x)$

Статистика Колмогорова: $D_n(X_n) = \sup_{-\infty < x < +\infty} |F_n^*(x) - F(x)|$

Критерий Колмогорова: Основная гипотеза H_0 принимается, если

$$P(\sqrt{n}D_n(X_n) \leq \lambda_\alpha | H_0) = \alpha,$$

где λ_α :

$$K(\lambda_\alpha) = \sum_{k=-\infty}^{\infty} (-1)^k e^{-2k^2 \lambda_\alpha^2} = 1 - \alpha$$

Критерий согласия χ^2 Пирсона.

H_0 - выборка X_n взята из значений дискретной случайной величины ξ ,
принимающей m различных значений $\{x_k\}_{k=1}^m$ с вероятностями $p_1, p_2, \dots, p_m$.

Статистика Пирсона: $X_n^2 = n \sum_{k=1}^m \frac{\left(\frac{m_k}{n} - p_k\right)^2}{p_k}$

Критерий согласия χ^2 Пирсона : Основная гипотеза H_0 принимается, если

$$X_n^2 \leq \chi_{m-1, \alpha}^2,$$

где $\chi_{m-1, \alpha}^2$ - находятся по таблицам критических значений распределения хи-квадрат с $m-1$ степенью свободы.

Пример применения критерия Пирсона.

Проверяем монету на идеальность.

Основная гипотеза H_0 - монета честная.

Статистика: Решка – 45 раз, Орел -55 раз.

$$m = 2; n = 100; p_1 = 0,5, p_2 = 0,5; m_1 = 45, m_2 = 55$$



$$\chi^2_{100} = 100 \cdot \frac{\left(\frac{45}{100} - 0,5\right)^2}{0,5} + 100 \frac{\left(\frac{55}{100} - 0,5\right)^2}{0,5} = 1$$

При уровне значимости $\alpha = 0,05$ получаем: $1 = \chi^2_{100} \leq \chi^2_{1,0.05} = 3,8 \Rightarrow$ основную гипотезу принимаем(монета честная).

Максимально правдоподобные гипотезы. Байесовский подход.

Группа событий $H_1, H_2, \dots, H_n$ называются *гипотезами*, если они удовлетворяют следующим требованиям:

- 1) $H_1, H_2, \dots, H_n$ - попарно несовместны;
- 2) $A \subset H_1 + H_2 + \dots + H_n$, $P(H_1) + P(H_2) + \dots + P(H_n) = 1$ ($\Omega = H_1 + H_2 + \dots + H_n$)

MAP-гипотеза: гипотеза H_i , которая имеет наибольшую условную вероятность: $P(H_i|A)$

Пусть событие A состоит из произведения элементарных событий A_i : $A = A_1 A_2 \dots A_m$
Наивный байесовский классификатор: считаем, что события $A_1, A_2, \dots, A_m$ - независимые.
Найти гипотезу H_{i^*} :

$$\max_i P(H_i)P(A_1|H_i) \dots P(A_m|H_i) = \prod_{k=1}^m P(H_{i^*})P(A_k|H_{i^*})$$

Формула Байеса.

$$P(H_i|A) = \frac{P(A|H_i)P(H_i)}{\sum_{k=1}^n P(A|H_k)P(H_k)}$$

Пример: В предприятии:
женщины 60%, мужчины 40%



- A_1 - наличие второго высшего образования
- A_2 - рост выше 175см.
- A_3 -знание иностранного языка
- A_4 - наличие водительских прав.

	$P(A_1)$	$P(A_2)$	$P(A_3)$	$P(A_4)$
Женщины	0.3	0.2	0.5	0.15
Мужчины	0.6	0.5	0.4	0.3

$A = \{\text{сотрудник } X \text{ имеет второе высшее образование, рост } 172\text{см, знает английский язык, не имеет водительских прав}\}$

Вопрос: Этот сотрудник X – мужчина или женщина?



Спасибо за внимание!

Дисциплина: Теория вероятностей и математическая статистика

Лектор: Егорова Алена Андреевна, к.ф.-м.н, доцент
кафедры Высшей математики -3 ИПТИП

e-mail: egorova@mirea.ru

Online-edu.mirea.ru

mirea.ru